

Metody Inteligencji Obliczeniowej

Predykcja zainteresowania postami w social media z użyciem
metod NLP

Dokumentacja projektu



Wydział Fizyki i Informatyki Stosowanej

Jan Kot, Krystsina Mironenka, Mikhail Shupliakou

10.06.2026

Spis treści

1	Cel i zakres projektu	3
2	Dane wejściowe	3
3	Eksploracyjna analiza danych	4
4	Przetwarzanie danych i reprezentacja tekstu	4
5	Podział danych	5
6	Modele i metryki	6
7	Analiza SHAP	7
8	Porównanie Ridge i SHAP	11
9	Wnioski	12
10	Linki i źródła projektu	12

1 Cel i zakres projektu

Celem projektu było zbudowanie modelu przewidującego zainteresowanie postami w mediach społecznościowych z wykorzystaniem metod NLP. Jako miarę zainteresowania przyjęto liczbę retweetów, a jako zbiór danych wykorzystano publiczny zestaw *Trump Tweets* z platformy Kaggle. Każda obserwacja opisuje pojedynczy tweet i zawiera między innymi treść wpisu, datę publikacji, liczbę retweetów, liczbę polubień, wzmianki oraz hashtagi.

Projekt realizuje następujące zadania:

- przygotowanie danych tekstowych i metadanych,
- reprezentację treści tweetów metodą TF-IDF,
- zbudowanie kilku modeli regresyjnych dla zmiennej $\log_{1p}(\text{retweets})$,
- ocenę wyników na skali logarytmicznej oraz oryginalnej,
- analizę wpływu przesunięcia czasowego,
- interpretację modelu końcowego przy użyciu SHAP.

2 Dane wejściowe

Po wczytaniu zbioru danych uzyskano 43 352 rekordy. Zakres dat obejmuje okres od 4 maja 2009 roku do 17 czerwca 2020 roku. Najważniejsze kolumny użyte w projekcie to:

- **content** – treść tweeta,
- **date** – data i czas publikacji,
- **retweets** – liczba retweetów, czyli zmienna przewidywana,
- **mentions i hashtags** – dodatkowe informacje strukturalne,
- **favorites** – liczba polubień, używana głównie do eksploracji, nie jako podstawowa cecha predykcyjna.


Rozkład liczby retweetów jest silnie skośny. Mediana wynosi około 396.5 retweeta, średnia około 6265, a maksimum 302 269. Oznacza to, że pojedyncze viralowe tweety bardzo mocno wpływają na średnią i utrudniają klasyczną regresję. Z tego powodu modele trenowano na transformacji:

$$y = \log(1 + \text{retweets}).$$

Metryki raportowano jednak zarówno na skali logarytmicznej, jak i po przekształceniu odwrotnym do oryginalnej skali retweetów.

3 Eksploracyjna analiza danych

Najważniejszą obserwacją z EDA jest zmienność danych w czasie. Starsze tweety pochodzą z okresu, gdy konto miało mniejszy zasięg i Twitter funkcjonował w innym kontekście społecznym. Późniejsze wpisy, szczególnie z okresu kampanii prezydenckiej i prezydentury, mają znacznie wyższe wartości retweetów.



Rysunek 1: Liczba tweetów oraz rozkład retweetów według roku. Drugi wykres używa skali logarytmicznej, aby pokazać silny wzrost mediany i 90. percentyla w późniejszych latach.

Rysunek 1 pokazuje dwa istotne zjawiska. Po pierwsze, liczba tweetów nie jest równomierna w kolejnych latach. Najwięcej wpisów pojawia się w latach 2012–2015, natomiast późniejsze lata mają mniej obserwacji, ale znacznie większy poziom zaangażowania. Po drugie, mediana i 90. percentyl retweetów wyraźnie rosną po 2015 roku. To wskazuje na przesunięcie rozkładu, które może powodować słabe wyniki przy zwykłym losowym podziale danych.

Z tego powodu w projekcie wprowadzono dwa warianty danych:

1. **all years** – pełny zakres lat 2009–2020,
2. **2015+** – tylko tweety od 1 stycznia 2015 roku.

Drugi wariant nie usuwa danych po cichu, lecz stanowi kontrolowany eksperyment redukujący różnice między bardzo starym i późnym okresem aktywności konta.

4 Przetwarzanie danych i reprezentacja tekstu

Pipeline przetwarzania został zaprojektowany tak, aby notebook można było uruchomić od początku do końca. Surowy plik danych jest przechowywany w jednej lokalizacji:

```
data/raw/trumptweets.csv.
```

Artefakty przetworzone, wektoryzator, skaler, modele i metadane podziałów są zapisywane w katalogu `processed/`.

Czyszczenie tekstu obejmowało:

- zamianę tekstu na małe litery,
- usunięcie linków URL,

- usunięcie nazw użytkowników,
- uproszczenie hashtagów,
- usunięcie znaków innych niż litery,
- usunięcie nadmiarowych białych znaków.

Do reprezentacji tekstu zastosowano TF-IDF z unigramami i bigramami. Ustawiono limit 5000 cech tekstowych, aby zachować rozsądny kompromis między bogactwem reprezentacji a czasem obliczeń. TF-IDF jest prostą, interpretowalną i dobrze dopasowaną metodą do modeli liniowych pracujących na rzadkich macierzach.

Oprócz tekstu przygotowano zestaw metadanych:

- długość tweeta w znakach i słowach,
- obecność URL, hashtagów i wzmianek,
- liczba hashtagów i wzmianek,
- godzina, dzień tygodnia, miesiąc,
- rok oraz liczba dni od pierwszego tweeta w danym wariancie danych.

Cecha `days_since_first` jest szczególnie ważna metodologicznie. Może poprawiać wynik, ponieważ opisuje trend wzrostu zasięgu konta, ale jednocześnie sprawia, że model nie jest modelem czysto NLP. Dlatego porównano warianty z cechami czasu oraz bez silnych cech czasu.

5 Podział danych

W projekcie zastosowano podział chronologiczny:

- 70% najstarszych obserwacji – zbiór treningowy,
- kolejne 15% – zbiór walidacyjny,
- ostatnie 15% – zbiór testowy.

Taki podział symuluje realistyczne zadanie: model uczy się na starszych tweetach i przewiduje zainteresowanie tweetami z przyszłości. Jest to ważniejsze niż losowy podział, ponieważ losowanie wymieszałoby stare i nowe okresy oraz sztucznie ułatwiło zadanie.

TF-IDF oraz `StandardScaler` są dopasowywane wyłącznie na zbiorze treningowym. Zbiory walidacyjny i testowy są jedynie transformowane przy użyciu obiektów nauczonych na treningu. Oznacza to, że informacje z przyszłych tweetów nie wpływają na reprezentację tekstu ani skalowanie metadanych.

Metadane zapisano oddzielnie dla każdego podziału:

- `df_train_meta.csv`,
- `df_val_meta.csv`,
- `df_test_meta.csv`.

Indeksy tych plików zostały zresetowane, dzięki czemu wiersz `i` w macierzy `X_test` odpowiada wierszowi `i` w `df_test_meta.csv`. Ma to kluczowe znaczenie dla poprawnych przykładów SHAP.

6 Modele i metryki

Porównano trzy grupy modeli:


- **DummyRegressor** – model bazowy przewidujący średnią wartość celu ze zbioru treningowego,
- **Ridge Regression** – prosty model liniowy dobrze współpracujący z rzadką reprezentacją TF-IDF,
- **XGBoost** – nieliniowy model drzewiasty zdolny wykorzystywać interakcje między tekstem i metadanymi.

Modele oceniano na dwóch skalach. Na skali logarytmicznej raportowano RMSE, MAE i R^2 . Po transformacji odwrotnej $\exp(y) - 1$ raportowano MAE oraz R^2 w oryginalnej skali retweetów. Ujemne R^2 nie zostało ukryte. Oznacza ono, że model jest gorszy od prostego przewidywania średniej na danym podziale. W tym zadaniu jest to możliwe ze względu na przesunięcie czasowe, viralowe outliersy i zmienne tło polityczne.

Tabela 1: Najważniejsze warianty eksperymentu.

Wariant	Cechy	Model	RMSE log wal.	RMSE log test	R^2 log test
all years	text + meta + time	XGBoost	ok. 1.0	ok. 1.3	ujemne
2015+	text only	XGBoost	ok. 1.0	ok. 1.6	ujemne
2015+	text + meta bez czasu	XGBoost	ok. 0.9	ok. 1.5	ujemne
2015+	text + meta + time	XGBoost	0.408	0.597	-0.034

Najlepszą konfiguracją wybraną na podstawie walidacji był wariant **2015+**, zestaw cech **text + metadata + time** oraz model **XGBoost**. Dla tej konfiguracji testowy RMSE na skali logarytmicznej wyniósł około 0.60. Jednocześnie R^2 na teście pozostało lekko ujemne, co pokazuje, że nawet najlepszy model nie rozwiązuje w pełni problemu przewidywania retweetów.




Rysunek 2: Porównanie testowego RMSE na skali logarytmicznej dla wariantów danych, zestawów cech i modeli. Najlepszy wynik osiąga XGBoost dla danych od 2015 roku z tekstem, metadany i cechami czasu.

Rysunek 2 pokazuje, że pełny zakres lat jest trudniejszy dla modelu niż wariant 2015+. Najgorsze wyniki uzyskują modele bazowe i warianty pełnohistoryczne, co jest zgodne z obserwacją o silnym przesunięciu rozkładu. Dodanie metadanych i czasu wyraźnie poprawia RMSE, ale należy interpretować to ostrożnie: część przewidywania pochodzi z trendu czasowego, a nie tylko z treści tweeta.


7 Analiza SHAP

Do interpretacji modelu końcowego użyto metody SHAP. Analizę wykonano na próbie 500 wierszy ze zbioru testowego, aby ograniczyć czas obliczeń. Nazwy cech obejmują zarówno cechy TF-IDF, jak i metadane. Przykłady lokalne są indeksowane względem `X_test`, a opis tweeta jest pobierany z dopasowanego `df_test_meta.csv`. Rozwiązuje to problem błędnego dopasowania predykcji do treści tweeta.




Rysunek 3: Globalna ważność cech według średniej bezwzględnej wartości SHAP. Najsilniejsze są cechy czasowe, szczególnie `days_since_first`.

Rysunek 3 pokazuje, że dominują cechy związane z czasem: `days_since_first`, `year` oraz pochodne okresu publikacji. Jest to zgodne z EDA: późniejsze tweety mają znacznie wyższe retweety, ponieważ konto funkcjonowało wtedy w innym kontekście i miało większy zasięg. Wśród cech tekstowych pojawiają się między innymi słowa i bigramy związane z tematyką polityczną oraz medialną. Ich wpływ jest interpretowalny, ale słabszy niż efekt czasu.




Rysunek 4: SHAP summary plot dla modelu końcowego. Kolor oznacza wartość cechy, a położenie punktu pokazuje wpływ na predykcję w skali logarytmicznej.

Summary plot pozwala odróżnić kierunek wpływu cech. Wysoka wartość `days_since_first` zwykle przesunęła predykcję w górę, co oznacza większą przewidywaną liczbę retweetów dla nowszych tweetów. Niektóre słowa zwiększają predykcję lokalnie, ale ich efekt jest zależny od kontekstu i interakcji z pozostałymi cechami. To ważna różnica względem Ridge Regression, gdzie współczynnik jest stały i liniowy.



Rysunek 5: Cechy zwiększające i zmniejszające predykcję według średnich wartości SHAP. Wykres pokazuje, że model łączy sygnały czasowe z wybranymi słowami TF-IDF.

Rysunek 5 pokazuje średni kierunek wpływu. Po stronie dodatniej znajduje się przede wszystkim `days_since_first`, ale również pewne słowa związane z kampanią, polityką i mediami. Po stronie ujemnej pojawiają się słowa lub tematy, które w analizowanej próbie częściej wiązały się z niższym przewidywanym zaangażowaniem. Nie należy jednak interpretować pojedynczych słów jako uniwersalnych reguł. TF-IDF nie rozumie pełnego kontekstu semantycznego, a XGBoost może wykorzystywać interakcje między wieloma cechami.



Rysunek 6: Waterfall plot dla jednego tweeta ze zbioru testowego. Przykład dotyczy tweeta z 31 maja 2020 roku o treści: “The United States of America will be designating ANTIFA as a Terrorist Organization.”

Dla przykładu z rysunku 6 rzeczywista liczba retweetów wyniosła 224 890, natomiast predykcja modelu wyniosła około 17 332. To bardzo dobry przykład ograniczeń regresji retweetów. Model rozpoznaje, że tweet jest późny czasowo i zawiera silne sygnały polityczne, ale nie jest w stanie przewidzieć pełnej viralowości wpisu. Takie przypadki pokazują, że błąd w oryginalnej skali może być bardzo duży nawet wtedy, gdy model działa sensownie na skali logarytmicznej.

8 Porównanie Ridge i SHAP

W projekcie porównano współczynniki modelu Ridge z wartościami SHAP modelu końcowego. Korelacja Pearsona w widocznym uruchomieniu wyniosła około 0.079, czyli była bardzo słaba dodatnia. Nie należy więc pisać, że Ridge i SHAP dają silnie zgodne interpretacje.

Różnica jest metodologicznie uzasadniona:

- Ridge jest modelem liniowym, więc każda cecha ma jeden stały współczynnik,
- XGBoost jest modelem nieliniowym i może wykorzystywać progi oraz interakcje,

- SHAP opisuje wkład cechy w kontekście konkretnej obserwacji i rozkładu danych.

W praktyce Ridge jest dobrym punktem odniesienia dla reprezentacji TF-IDF, natomiast SHAP dla XGBoost lepiej pokazuje, jak model miesza wpływ czasu, metadanych i tekstu.

9 Wnioski

Projekt zakończył się zbudowaniem poprawnego pipeline’u NLP do predykcji zainteresowania tweetami. Najważniejsze usprawnienia metodologiczne to jednoznaczne ładowanie danych, chronologiczny podział, eliminacja wycieku przy TF-IDF i skalowaniu, porównanie pełnego zakresu lat z wariantem od 2015 roku oraz poprawne dopasowanie przykładów SHAP do wierszy testowych.

Wyniki pokazują, że przewidywanie liczby retweetów jest trudne. Nawet najlepszy model, XGBoost dla danych 2015+ z tekstem, metadany i cechami czasu, nie daje stabilnie wysokiego R^2 . Jest to zgodne z naturą problemu: retweety zależą od zewnętrznego kontekstu politycznego, liczby obserwujących, działania algorytmów platformy i przypadkowej viralowości.

TF-IDF pozwala uzyskać interpretowalne cechy tekstowe, ale analiza SHAP pokazuje, że bardzo duże znaczenie mają także cechy temporalne. Dlatego modelu nie należy opisywać jako czysto językowego. Jest to raczej model łączący reprezentację tekstu z informacją o czasie publikacji i prostymi metadanymi.

Możliwe kierunki rozwoju projektu:

- zastosowanie embeddingów kontekstowych, np. BERT lub sentence transformers,
- dodanie liczby obserwujących w momencie publikacji tweeta,
- osobna klasyfikacja tweetów viralowych zamiast samej regresji,
- użycie odporniejszych funkcji straty,
- walidacja krocząca w czasie zamiast pojedynczego podziału 70/15/15.

Podsumowując, projekt spełnia cel dydaktyczny: pokazuje pełny proces budowy modelu NLP, uczciwą ewaluację czasową oraz interpretację wyników. Najważniejszy wniosek praktyczny jest ostrożny: tekst i metadane pozwalają częściowo analizować zainteresowanie tweetami, ale dokładna predykcja retweetów pozostaje problemem trudnym i silnie zależnym od czynników spoza samej treści wpisu.

10 Linki i źródła projektu

Kod źródłowy projektu oraz notebook z eksperymentami znajduje się w repozytorium:

- Repozytorium projektu: [TU_WSTAW_LINK_DO_GITHUBA](#)

W projekcie wykorzystano następujące źródła danych oraz biblioteki:

- Zbiór danych Trump Tweets na Kaggle: <https://www.kaggle.com/datasets/austinreese/trump-tweets>

- Dokumentacja scikit-learn – TF-IDF Vectorizer: https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html
- Dokumentacja scikit-learn – Ridge Regression: https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Ridge.html
- Dokumentacja scikit-learn – DummyRegressor: <https://scikit-learn.org/stable/modules/generated/sklearn.dummy.DummyRegressor.html>
- Dokumentacja scikit-learn – metryki regresji: https://scikit-learn.org/stable/modules/model_evaluation.html#regression-metrics
- Dokumentacja XGBoost: <https://xgboost.readthedocs.io/>
- Dokumentacja SHAP: <https://shap.readthedocs.io/>
- Dokumentacja pandas: <https://pandas.pydata.org/docs/>
- Dokumentacja NumPy: <https://numpy.org/doc/>